

# การสำรวจและวิเคราะห์เชิงลึกเกี่ยวกับแบบจำลอง การดัดแปลง และการประยุกต์ใช้ในการติดตามความรู้ (Knowledge Tracing)

ในยุคสมัยที่การศึกษาออนไลน์และระบบการเรียนรู้แบบปรับเหมาะ (Adaptive Learning) กลายเป็นแกนกลางของการพัฒนาศักยภาพมนุษย์ การวิเคราะห์ข้อมูลพฤติกรรมของผู้เรียนอย่างเป็นระบบจึงมีความสำคัญอย่างยิ่งยวด บทความวิจัยเรื่อง "A Survey of Knowledge Tracing: Models, Variants, and Applications" นำเสนอภาพรวมที่ครอบคลุมของงานวิจัยในสาขาการติดตามความรู้ (Knowledge Tracing หรือ KT) ซึ่งเป็นเทคนิคพื้นฐานในการตรวจสอบสถานะความรู้ที่เปลี่ยนแปลงไปของนักเรียนในระหว่างกระบวนการแก้ปัญหา<sup>1</sup> การกิจหลักของการติดตามความรู้คือการสร้างแบบจำลองทางคณิตศาสตร์หรือคอมพิวเตอร์เพื่อประเมินระดับความเชี่ยวชาญในทักษะหรือองค์ประกอบความรู้ (Knowledge Concepts - KCs) ที่เฉพาะเจาะจง โดยอาศัยประวัติการตอบคำถามและปฏิสัมพันธ์ที่บันทึกไว้ในระบบการศึกษาออนไลน์<sup>2</sup> รายงานฉบับนี้จะเจาะลึกถึงรายละเอียดของโครงสร้างแบบจำลองพื้นฐาน การดัดแปลงเพื่อเพิ่มความแม่นยำ และการประยุกต์ใช้ในสถานการณ์จริง พร้อมทั้งวิเคราะห์ทิศทางในอนาคตที่ได้รับอิทธิพลจากเทคโนโลยีปัญญาประดิษฐ์ยุคใหม่

## รากฐานและนิยามของปัญหาการติดตามความรู้

การติดตามความรู้ไม่ได้เป็นเพียงการคาดการณ์ว่านักเรียนจะตอบคำถามถูกหรือไม่ แต่เป็นการสร้าง "กระจก" ที่สะท้อนสถานะทางปัญญาที่แท้จริงของผู้เรียน<sup>2</sup> ปัญหานี้ถูกนิยามผ่านลำดับของปฏิสัมพันธ์การเรียนรู้ที่ประกอบด้วยชุดของนักเรียน (S) และชุดของแบบฝึกหัด (E) โดยแต่ละแบบฝึกหัดจะมีความเชื่อมโยงกับองค์ประกอบความรู้ (KCs) ที่ระบุไว้ใน Q-matrix<sup>4</sup> ลำดับการเรียนรู้ของนักเรียนสามารถเขียนแทนด้วยชุดข้อมูลแบบทวิภาคที่บันทึกการหัดแบบฝึกหัด รหัสความรู้ที่เกี่ยวข้อง ผลลัพธ์การตอบ (ถูกหรือผิด) และข้อมูลเสริมอื่น ๆ เช่น เวลาที่ใช้ในการตอบหรือจำนวนครั้งที่ขอคำใบ้<sup>4</sup>

เป้าหมายสูงสุดของ KT คือการใช้ข้อมูลย้อนหลังเหล่านี้เพื่อคาดการณ์ประสิทธิภาพในอนาคตและประเมิน "ระดับความเชี่ยวชาญ" (Mastery Level) ซึ่งเป็นตัวแปรแฝงที่ไม่สามารถสังเกตได้โดยตรง<sup>2</sup> ความท้าทายที่สำคัญของสาขานี้คือการสร้างแบบจำลองที่สามารถรับมือกับความซับซ้อนของมนุษย์ เช่น อัตราการเรียนรู้ที่แตกต่างกัน การลืมเลือน และความไม่สม่ำเสมอของสมาธิในระหว่างการทำแบบทดสอบ<sup>4</sup>

## ข้อมูลพื้นฐานและสถิติที่ใช้ในการวิจัยการติดตามความรู้

การวิจัยในสาขานี้อาศัยชุดข้อมูลสาธารณะที่รวบรวมจากแพลตฟอร์มการเรียนรู้ระดับโลก ซึ่งแต่ละชุดข้อมูลมีลักษณะเฉพาะที่แตกต่างกันไปตามวิชาและระดับชั้นของผู้เรียน<sup>2</sup>

ชื่อชุดข้อมูล	สาขาวิชา	ระดับการศึกษา	จำนวนนักเรียน	จำนวน KCs	จำนวนบันทึกการเรียนรู้
ASSISTment	คณิตศาสตร์	มัธยมศึกษา	4,163	123	346,860

s2009		ตอนต้น			
ASSISTment s2012	คณิตศาสตร์	มัธยมศึกษา ตอนต้น	46,674	265	6,123,270
EdNet-KT1	ภาษาอังกฤษ	ทั่วไป	784,309	188	95,293,926
Junyi	คณิตศาสตร์	ประถม- มัธยมปลาย	247,606	41	25,925,922
Eedi2020	คณิตศาสตร์	ประถม- มัธยมปลาย	118,971	388	15,867,850
Statics2011	วิศวกรรมศาส ตร์	มหาวิทยาลัย	335	80	361,092

ความหลากหลายของข้อมูลเหล่านี้ทำให้นักวิจัยสามารถทดสอบความทนทาน (Robustness) ของแบบจำลองใน  
สภาวะที่แตกต่างกัน เช่น ชุดข้อมูล EdNet ที่มีขนาดมหึมาและเน้นทักษะภาษา หรือชุดข้อมูล Statics2011 ที่  
เน้นความรู้เชิงโครงสร้างที่มีความซับซ้อนสูง <sup>2</sup>

## แบบจำลองพื้นฐานสามสายหลัก

บทความวิจัยต้นฉบับแบ่งเส้นทางเทคนิคของ KT ออกเป็นสามกลุ่มหลัก ได้แก่ แบบจำลองเบย์เซียน  
(Bayesian Models) แบบจำลองโลจิสติก (Logistic Models) และแบบจำลองการเรียนรู้เชิงลึก (Deep  
Learning Models) <sup>1</sup>

### แบบจำลองเบย์เซียน: Bayesian Knowledge Tracing (BKT)

Bayesian Knowledge Tracing (BKT) เป็นแบบจำลองที่มีความสำคัญทางประวัติศาสตร์และยังคงถูกใช้งาน  
อย่างกว้างขวางเนื่องจากมีความสามารถในการตีความที่ยอดเยี่ยม <sup>5</sup> BKT ตั้งอยู่บนสมมติฐานของ Hidden  
Markov Model (HMM) โดยมองว่าสถานะความรู้ของนักเรียนเป็นตัวแปรสุ่มแบบทวิภาค (Binary Latent  
Variable) คือ "รู้" (Mastered) หรือ "ไม่รู้" (Unmastered) <sup>5</sup>

โครงสร้างของ BKT ประกอบด้วยพารามิเตอร์หลัก 4 ตัวที่กำหนดพฤติกรรมการเรียนรู้:

พารามิเตอร์	สัญลักษณ์	ความหมายเชิงการศึกษา
Initial Mastery	$P(L_0)$	ความน่าจะเป็นที่นักเรียนจะมีค วามรู้พื้นฐานอยู่แล้วก่อนเริ่ม

		เรียน
Transition (Learn)	$P(T)$	ความน่าจะเป็นที่นักเรียนจะเปลี่ยนจากสถานะไม่รู้เป็นรู้หลังจากได้ฝึกฝน
Guess	$P(G)$	ความน่าจะเป็นที่นักเรียนจะตอบถูกแม้ว่าจะยังไม่มีความรู้ (การเดา)
Slip	$P(S)$	ความน่าจะเป็นที่นักเรียนจะตอบผิดทั้งที่มีความรู้แล้ว (การพลั้งเพลอ)

กลไกการอัปเดตสถานะความรู้จะเกิดขึ้นทุกครั้งที่มีการตอบคำถาม โดยใช้กฎของเบย์เซียนเพื่อคำนวณความน่าจะเป็นหลัง (Posterior Probability) จากผลการตอบที่สังเกตได้<sup>5</sup> อย่างไรก็ตาม BKT มีข้อจำกัดที่สำคัญคือการสมมติว่าแต่ละทักษะมีความเป็นอิสระต่อกัน และมักจะไม่นำเนื้องานลืม (No Forgetting Assumption) แม้ว่าจะมีการดัดแปลงในภายหลังเพื่อใส่พารามิเตอร์การลืมเข้าไปก็ตาม<sup>5</sup>

ปัญหาหนึ่งที่พบบ่อยใน BKT คือ "ความเสื่อมถอยของแบบจำลองเชิงความหมาย" (Semantic Model Degeneracy) ซึ่งเกิดขึ้นเมื่อกระบวนการหาค่าพารามิเตอร์ที่เหมาะสม (Optimization) นำไปสู่ค่าที่ขัดกับตรรกะทางการศึกษา เช่น ค่า  $P(G)$  ที่สูงกว่าค่า  $1 - P(S)$  ซึ่งหมายความว่าคนไม่รู้มีโอกาสตอบถูกมากกว่าคนรู้<sup>9</sup> นักวิจัยจึงต้องมีการกำหนดขอบเขตของพารามิเตอร์ (Parameter Constraints) เพื่อรักษาความหมายเชิงครู (Pedagogical Meaning) ของแบบจำลองไว้<sup>9</sup>

### แบบจำลองโลจิสติกและปัจจัยการวิเคราะห์

แบบจำลองกลุ่มนี้ใช้ฟังก์ชันโลจิสติกในการทำนายโอกาสที่นักเรียนจะตอบถูก โดยพิจารณาจากปัจจัยต่าง ๆ เช่น ความสามารถของนักเรียน ความยากของคำถาม และจำนวนครั้งที่เคยฝึกฝน<sup>2</sup> ตัวอย่างที่สำคัญ ได้แก่:

- **Learning Factor Analysis (LFA):** ผสมผสานแนวคิดของ Item Response Theory (IRT) เข้ากับการติดตามการเรียนรู้ โดยพิจารณาจากความง่ายขององค์ประกอบความรู้และอัตราการเรียนรู้ของนักเรียนแต่ละคน<sup>2</sup>
- **Performance Factor Analysis (PFA):** เป็นการต่อยอดที่เน้นความไวต่อผลลัพธ์การเรียนรู้ โดยแยกพิจารณาผลกระทบของ "ความสำเร็จ" (Successes) และ "ความล้มเหลว" (Failures) ในอดีตออกจากกัน ซึ่งงานวิจัยพบว่าการตอบถูกและการตอบผิดส่งผลต่อการเปลี่ยนแปลงสถานะความรู้ในระดับที่ต่างกัน<sup>2</sup>
- **Knowledge Tracing Machines (KTM):** ใช้เทคนิค Factorization Machines เพื่อขยายขีดความสามารถของแบบจำลองโลจิสติกให้รองรับข้อมูลเสริมขนาดใหญ่และซับซ้อนได้มากขึ้น<sup>2</sup>

## แบบจำลองการเรียนรู้เชิงลึก (Deep Learning Models)

การเกิดขึ้นของ Deep Knowledge Tracing (DKT) ในปี 2015 ได้ปฏิวัติวงการด้วยการนำโครงข่ายประสาทเทียมแบบเวียนซ้ำ (Recurrent Neural Networks - RNN) มาใช้<sup>1</sup> DKT สามารถเรียนรู้ความสัมพันธ์ระหว่างทักษะต่าง ๆ ได้โดยอัตโนมัติจากข้อมูลดิบ โดยไม่ต้องอาศัยการกำหนดความสัมพันธ์โดยผู้เชี่ยวชาญ (Expert Tagging) ในลักษณะเดียวกับ BKT<sup>2</sup>

วิวัฒนาการของแบบจำลองเชิงลึกสามารถแบ่งออกได้เป็นสี่กลุ่มย่อย:

- DKT และตัวแปรเสริม:** ใช้หน่วยความจำระยะสั้นยาว (LSTM) หรือ GRU เพื่อจัดการกับลำดับการเรียนรู้ที่มีความยาว และสร้างเวกเตอร์สถานะความรู้ที่มีมิติสูง<sup>2</sup>
- Memory-Aware KT (DKVMN):** นำโครงสร้างหน่วยความจำภายนอก (External Memory) มาใช้ โดยแยกส่วนที่เก็บองค์ประกอบความรู้ (Key Matrix) และส่วนที่เก็บระดับความเชี่ยวชาญ (Value Matrix) เพื่อเพิ่มความสามารถในการตีความและความแม่นยำ<sup>2</sup>
- Attentive KT (AKT):** ใช้กลไกความสนใจ (Attention Mechanism) เพื่อให้น้ำหนักกับปฏิสัมพันธ์ในอดีตที่เกี่ยวข้องกับคำถามปัจจุบันมากที่สุด โดยแบบจำลองอย่าง AKT และ SAINT ได้แสดงให้เห็นถึงประสิทธิภาพที่เหนือกว่า DKT อย่างมากในด้านความแม่นยำในการทำนาย<sup>2</sup>
- Graph-based KT (GKT):** ใช้โครงข่ายประสาทเทียมแบบกราฟ (GNN) เพื่อจำลองความสัมพันธ์เชิงโครงสร้างของความรู้ เช่น ความสัมพันธ์แบบเป็นเหตุเป็นผลหรือลำดับก่อนหลัง (Prerequisite) ระหว่าง KCs<sup>2</sup>

## การดัดแปลงแบบจำลองและการพิจารณาสมมติฐานที่เข้มงวด

ในความเป็นจริง กระบวนการเรียนรู้ไม่ได้เรียบง่ายเพียงแค่การตอบคำถามไปตามลำดับ แต่มีปัจจัยแวดล้อมมากมายที่ส่งผลกระทบต่อผลลัพธ์<sup>4</sup> งานวิจัยรุ่นหลังจึงมุ่งเน้นไปที่การสร้างแบบจำลองที่พิจารณาสมมติฐานที่สมจริงยิ่งขึ้น

### การสร้างแบบจำลองความเป็นส่วนตัว (Individualization)

นักเรียนแต่ละคนมี "ความเร็วในการเรียนรู้" และ "ความรู้พื้นฐาน" ที่ไม่เท่ากัน<sup>2</sup> งานวิจัยเรื่อง Individualized BKT พบว่าการใส่พารามิเตอร์เฉพาะตัวของนักเรียนเข้าไปในแบบจำลองช่วยลดความคลาดเคลื่อนได้อย่างมีนัยสำคัญ โดยเฉพาะการปรับแต่งอัตราการเรียนรู้ ( $P(T_i)$ ) ซึ่งมีผลมากกว่าการปรับแต่งความรู้เริ่มต้น ( $P(L_0)$ ) เสียด้วยซ้ำ<sup>6</sup> นอกจากนี้ เทคนิคการจัดกลุ่มนักเรียน (Clustering) เช่น ใน DKT-DSC ช่วยให้ระบบสามารถเลือกใช้แบบจำลองที่เหมาะสมกับระดับความสามารถของนักเรียนแต่ละกลุ่มได้อย่างมีประสิทธิภาพ<sup>2</sup>

กลยุทธ์การปรับแต่งความเป็นส่วนตัว	กลไกการทำงาน	ประโยชน์ที่ได้รับ
Prior Per Student (PPS)	กำหนดค่า $P(L_0)$ เฉพาะรายบุคคล	ช่วยแก้ปัญหาการประเมินความรู้พื้นฐานที่คลาดเคลื่อนในช่วงเริ่มต้น

Transition Individualization	ปรับค่า $P(T)$ ตามอัตราการรับรู้ของนักเรียน	สะท้อนถึงความเร็วในการเรียนรู้ที่แตกต่างกันของนักเรียนแต่ละคน
Clustering-based KT	แบ่งนักเรียนเป็นกลุ่มตามระดับความสามารถ	ลดความซับซ้อนของแบบจำลองและเพิ่มความแม่นยำในการทำนาย

### การรวมปัจจัยความมุ่งมั่น (Engagement) และพฤติกรรม

พฤติกรรมในขณะเรียน เช่น การใช้เวลาที่สั้นผิดปกติ (Gaming the System) หรือการขอคำใบ้ซ้ำ ๆ เป็นตัวบ่งชี้สำคัญถึงสถานะความรู้และอารมณ์<sup>4</sup> แบบจำลอง LBAKT (Learning Behaviors and Ability Knowledge Tracing) ได้พิสูจน์แล้วว่า การรวมข้อมูลเวลาในการตอบ (Response Time) และการใช้คำใบ้ (Hint Usage) เข้าไปช่วยให้การติดตามความรู้มีความเสถียรมากขึ้นและลดความไม่แน่นอนของคำตอบแบบสุ่ม<sup>4</sup> นอกจากนี้ยังมีการทดลองนำข้อมูลจากเซนเซอร์ เช่น คลื่นสมอง (EEG) มาช่วยประเมินสถานะทางจิตใจของนักเรียนในระหว่างการเรียนรู้อีกด้วย<sup>2</sup>

### การพิจารณาการลืม (Forgetting)

สมมติฐานที่ว่า "เรียนแล้วไม่ลืม" เป็นจุดอ่อนสำคัญของแบบจำลองดั้งเดิม ทฤษฎีเส้นโค้งการลืมของ Ebbinghaus แสดงให้เห็นว่าความรู้จะเสื่อมถอยลงตามกาลเวลา<sup>4</sup> แบบจำลองรุ่นใหม่จึงนำปัจจัยของ "ช่วงเวลาว่าง" (Time Gap) มาคำนวณ โดยใช้ฟังก์ชันการเสื่อมถอยแบบเอกซ์โพเนนเชียล (Exponential Decay) หรือกระบวนการ Hawkes (Hawkes Process) เพื่อปรับระดับความเชี่ยวชาญให้ลดลงหากนักเรียนไม่ได้ฝึกฝนทักษะนั้นเป็นเวลานาน<sup>2</sup>

### ประสิทธิภาพและการเปรียบเทียบ: ข้อถกเถียงเรื่อง "ความลึก"

หัวข้อที่น่าสนใจในการวิจัยคือคำถามว่า "แบบจำลองเชิงลึก (Deep) จำเป็นเสมอไปหรือไม่?" งานวิจัยของ Khajah et al. (2016) เรื่อง "How Deep is Knowledge Tracing?" ได้นำเสนอข้อโต้แย้งที่สำคัญ โดยแสดงให้เห็นว่าหากเราปรับแต่ง BKT ให้รองรับปัจจัยการลืม ความสามารถแฝง และลำดับของแบบฝึกหัด ประสิทธิภาพของ BKT จะสามารถขึ้นมาเทียบเท่ากับ DKT ได้<sup>15</sup>

ความแตกต่างที่แท้จริงอาจไม่ได้อยู่ที่ความแม่นยำเพียงอย่างเดียว แต่อยู่ที่:

- การจัดการกับข้อมูลเบาบาง (Cold Start):** แบบจำลองสมัยใหม่อย่าง DKVMN มีข้อดีในการถ่ายโอนความรู้ระหว่างทักษะ ทำให้สามารถทำนายผลลัพธ์ของนักเรียนในทักษะใหม่ได้ดีกว่า BKT หรือ PFA ที่มองว่าแต่ละทักษะตัดขาดจากกัน<sup>18</sup>
- ความสอดคล้องและการตีความ:** DKT มักประสบปัญหาการทำนายที่ไม่สอดคล้องกัน (เช่น ตอบถูกแล้วความรู้ลดลง) ซึ่งแบบจำลองอย่าง BKT หรือแบบจำลองที่มีการใส่ข้อจำกัดทางครู (Pedagogical Constraints) จะมีความเสถียรและน่าเชื่อถือมากกว่าในมุมมองของผู้ใช้งาน<sup>4</sup>

## การประยุกต์ใช้ในสถานการณ์การเรียนรู้จริง

เทคโนโลยี KT ไม่ได้หยุดอยู่แค่ในห้องวิจัย แต่ได้ถูกนำไปสร้างระบบที่มีประสิทธิภาพในโลกแห่งความเป็นจริง <sup>2</sup>

### การแนะนำทรัพยากรการเรียนรู้ (Learning Resources Recommendation)

ระบบแนะนำแบบฝึกหัดที่ใช้ KT เป็นพื้นฐานจะช่วยเลือกแบบฝึกหัดที่อยู่ใน "โซนการพัฒนาที่ใกล้เคียง" (Zone of Proximal Development) ของนักเรียน คือไม่ยากจนเกินไปจนท้อ และไม่ง่ายจนเกินไปจนเบื่อ <sup>2</sup> การศึกษาพบว่าอัลกอริทึม BKT-sequence ช่วยให้นักเรียนสามารถแก้ปัญหาที่ยากขึ้นได้ในเวลาที่สั้นลง และมีความพึงพอใจในการเรียนเพิ่มขึ้น <sup>2</sup>

### การเรียนรู้แบบปรับเหมาะ (Adaptive Learning)

ในระบบอย่าง Massive Open Online Courses (MOOCs) มีการใช้ KT เพื่อสร้างเส้นทางการเรียนรู้แบบพลวัต (Dynamic Learning Pathways) <sup>2</sup> ตัวอย่างเช่น ระบบ CSEAL ที่รวม DKT เข้ากับโครงสร้างความรู้และอัลกอริทึมการนำทางเพื่อสร้างลำดับบทเรียนที่เป็นตรรกะและเหมาะสมกับสถานะความรู้ปัจจุบันของนักเรียน <sup>2</sup>

### การประยุกต์ใช้ในด้านอื่น ๆ

นอกจากด้านการศึกษาดังกล่าวแล้ว KT ยังถูกขยายขอบเขตไปสู่:

- **ระบบเกม:** การติดตามทักษะของผู้เล่นเพื่อปรับความยากของเกมให้เหมาะสม <sup>2</sup>
- **Crowdsourcing:** การประเมินความสามารถของผู้ทำงานในระบบ Crowdsourcing เพื่อมอบหมายงานตามความเชี่ยวชาญและรักษาคุณภาพของข้อมูล <sup>2</sup>
- **Citizen Science:** การตรวจสอบสถานะความรู้ของอาสาสมัครในการทำภารกิจวิทยาศาสตร์พลเมือง เช่น การจำแนกประเภทภาพดาราศาสตร์ <sup>2</sup>

## เครื่องมือและห้องสมุดอัลกอริทึมเพื่อการวิจัย

เพื่อลดอุปสรรคในการเข้าถึงและส่งเสริมการพัฒนาต่อยอด คณะผู้วิจัยได้เปิดซอร์สห้องสมุดอัลกอริทึมที่สำคัญสองชุด <sup>1</sup>:

1. **EduData:** ทำหน้าที่เป็นศูนย์กลางในการดาวน์โหลดและประมวลผลชุดข้อมูล KT มาตรฐาน (เช่น ASSISTments, EdNet, Junyi) ให้อยู่ในรูปแบบที่พร้อมใช้งาน ช่วยแก้ปัญหาความยุ่งยากในการเตรียมข้อมูลดิบที่มีความหลากหลายสูง <sup>1</sup>
2. **EduKTM:** รวบรวมการนำแบบจำลอง KT ยอดเยี่ยมมาปรับใช้อย่างเป็นระบบ (Model Zoo) ทั้ง BKT, DKT, DKVMN, AKT และอื่น ๆ โดยใช้วิธีการเขียนโค้ดที่เป็นมาตรฐานและรองรับเฟรมเวิร์กการเรียนรู้เชิงลึกที่หลากหลาย <sup>1</sup>

## พรมแดนใหม่: ยุคสมัยของ Large Language Models (LLMs)

ตั้งแต่ปี 2024 เป็นต้นมา การบูรณาการ Large Language Models เข้ากับการติดตามความรู้ได้เปิดมิติใหม่

## Dialogue Knowledge Tracing (DialogueKT)

งานวิจัยล่าสุดได้นำเสนอ "DialogueKT" ซึ่งเป็นการติดตามความรู้ผ่านบทสนทนาที่เป็นธรรมชาติระหว่างตัวเตอร์ (ที่เป็น AI หรือมนุษย์) กับนักเรียน <sup>20</sup> แทนที่จะใช้เพียงคำตอบถูก/ผิด ระบบจะใช้ LLM เช่น GPT-4o ในการวิเคราะห์เนื้อหาในบทสนทนาเพื่อระบุองค์ประกอบความรู้และความถูกต้องในแต่ละขั้นตอน <sup>20</sup> จากนั้นจะใช้แบบจำลองอย่าง LLMKT ที่ผ่านการ Fine-tuning จาก Llama 3 เพื่อประเมินสถานะความรู้จากข้อความโดยตรง ซึ่งให้ผลลัพธ์ที่แม่นยำกว่าการใช้รหัสทักษะแบบเดิมในกรณีที่มีข้อมูลการฝึกฝนจำกัด <sup>20</sup>

## การแก้ปัญหา Cold Start ด้วย LLMs

LLMs มีความสามารถในการเข้าใจความหมายของโจทย์ปัญหาอย่างลึกซึ้ง งานวิจัยพบว่าการใช้ LLM ในการสร้าง Knowledge Tagging อัตโนมัติและการคำนวณระดับความยากของคำถามช่วยให้ระบบ KT สามารถทำนายผลลัพธ์ของคำถามใหม่ที่ไม่เคยเห็นมาก่อนได้ดียิ่งขึ้น <sup>21</sup> นอกจากนี้ยังสามารถทำหน้าที่เป็นตัวเตอร์ที่อธิบายเหตุผลเบื้องหลังการประเมินความรู้ ทำให้นักเรียนเข้าใจจุดแข็งและจุดอ่อนของตนเองได้ชัดเจนขึ้น <sup>19</sup>

## การวิเคราะห์แนวทางการพัฒนาและต่อยอดในอนาคต

จากการสำรวจอย่างละเอียด เราสามารถวิเคราะห์ทิศทางที่สำคัญสำหรับการวิจัยการติดตามความรู้ในระยะต่อไปได้ดังนี้ <sup>2</sup>:

### 1. การเพิ่มความสามารถในการตีความ (Interpretability)

แม้ว่าแบบจำลองเชิงลึกจะมีความแม่นยำสูง แต่ความเป็น "กล่องดำ" ยังคงเป็นอุปสรรคในการนำไปใช้จริงในชั้นเรียน <sup>4</sup> งานวิจัยในอนาคตควรมุ่งเน้นไปที่การใช้เทคนิค Explainable AI (xAI) เพื่อเปิดเผยว่าแบบจำลองตัดสินใจระดับความเชี่ยวชาญจากปัจจัยใด หรือการสร้างแบบจำลองลูกผสม (Hybrid Models) ที่นำจุดเด่นด้านความแม่นยำของ Deep Learning มาผสมกับความสมเหตุสมผลของทฤษฎีทางปัญญา (Cognitive Theories) <sup>2</sup>

### 2. การจัดการกับข้อมูลเบาบาง (Sparse Data) และการปรับตัวข้ามโดเมน

ในระบบการศึกษาที่เพิ่งเริ่มต้นหรือวิชาที่มีผู้เรียนน้อย การขาดแคลนข้อมูลเป็นปัญหาใหญ่ <sup>2</sup> การพัฒนาเทคนิค Contrastive Learning หรือ Meta-learning เพื่อให้แบบจำลองสามารถเรียนรู้ได้จากข้อมูลจำนวนน้อย (Few-shot Learning) และการถ่ายโอนความรู้จากวิชาที่มีข้อมูลมากไปสู่วิชาที่มีข้อมูลน้อยเป็นหัวข้อที่ท้าทายอย่างยิ่ง <sup>2</sup>

### 3. การติดตามความรู้สำหรับคำถามแบบอัตนัย (Subjective Exercises)

งานวิจัยส่วนใหญ่ยังจำกัดอยู่กับคำถามปรนัยหรือคำตอบสั้น ๆ <sup>2</sup> การใช้ LLM ในการวิเคราะห์ความรู้จากคำตอบที่ยาวและซับซ้อน เช่น การเขียนโปรแกรม (Programming) การพิสูจน์ทางคณิตศาสตร์ หรือการเขียนเรียงความ จะเป็นก้าวสำคัญที่ทำให้ KT ครอบคลุมวิชาในสายสังคมศาสตร์และมนุษยศาสตร์ได้มากขึ้น <sup>20</sup>

### 4. ความเป็นส่วนตัวและความมั่นคงของข้อมูลนักเรียน

การติดตามข้อมูลในระดับละเอียด รวมถึงบทสนทนาและพฤติกรรมกรเรียน จำเป็นต้องมีการปกป้องความเป็นส่วนตัว



ส่วนตัวที่เข้มงวด<sup>2</sup> การวิจัยเกี่ยวกับ Federated Learning สำหรับ KT ซึ่งช่วยให้แบบจำลองสามารถเรียนรู้จากข้อมูลของหลายโรงเรียนได้โดยไม่ต้องมีการแบ่งปันข้อมูลดิบ จะมีความสำคัญมากขึ้นตามกฎหมายคุ้มครองข้อมูลส่วนบุคคลทั่วโลก<sup>2</sup>

## 5. การพัฒนา DKT2 และสถาปัตยกรรมยุคใหม่

แบบจำลอง DKT2 ที่ใช้สถาปัตยกรรม xLSTM แสดงให้เห็นว่าเราสามารถเพิ่มขีดความสามารถในการประมวลผลแบบขนานและความจุของหน่วยความจำได้โดยไม่สูญเสียความแม่นยำ<sup>23</sup> การค้นหาสถาปัตยกรรมโครงข่ายประสาทเทียมใหม่ ๆ ที่ออกแบบมาเพื่อข้อมูลการศึกษาโดยเฉพาะ (Domain-specific Architecture) ยังคงเป็นพื้นที่ที่เปิดกว้างสำหรับนักวิจัย<sup>25</sup>

## บทสรุป

การสำรวจงานวิจัยเรื่อง "A Survey of Knowledge Tracing: Models, Variants, and Applications" แสดงให้เห็นว่าการติดตามความรู้ได้เดินทางจากแบบจำลองความน่าจะเป็นพื้นฐานไปสู่สถาปัตยกรรมปัญญาประดิษฐ์ที่มีความซับซ้อนและทรงพลัง<sup>1</sup> ความสำเร็จของ KT ในทศวรรษหน้าจะไม่ขึ้นอยู่กับความแม่นยำเพียงอย่างเดียว แต่อยู่ที่การสร้างระบบที่ "เข้าใจมนุษย์" ได้อย่างแท้จริง ทั้งในแง่ของพฤติกรรม อารมณ์ และความแตกต่างระหว่างบุคคล<sup>4</sup> การบูรณาการ Large Language Models และการมุ่งเน้นที่ความสามารถในการตีความจะเป็นกุญแจสำคัญที่เปลี่ยนให้ KT กลายเป็นเครื่องมือที่มีประสิทธิภาพและได้รับความไว้วางใจจากครูและนักเรียนทั่วโลก ซึ่งจะส่งผลโดยตรงต่อการยกระดับคุณภาพการศึกษาของมนุษยชาติในวงกว้าง<sup>20</sup> นักวิจัยและนักปฏิบัติในฟิลด์นี้จึงควรใช้ประโยชน์จากเครื่องมือโอเพนซอร์สและชุดข้อมูลมาตรฐานที่มีอยู่ เพื่อร่วมกันผลักดันขีดจำกัดของเทคโนโลยีนี้ให้ก้าวไปข้างหน้าอย่างยั่งยืน<sup>2</sup>

## Works cited

1. A Survey of Knowledge Tracing: Models, Variants, and Applications, accessed February 8, 2026, <http://staff.ustc.edu.cn/~qiliuql/files/Publications/ShuanghongTLT2024.pdf>
2. 2105.15106v4.pdf
3. Knowledge Tracing Models in Digital Learning: Historical Evolution, Categorization, and Empirical Evaluation - ResearchGate, accessed February 8, 2026, [https://www.researchgate.net/publication/392398351\\_Knowledge\\_Tracing\\_Models\\_in\\_Digital\\_Learning\\_Historical\\_Evolution\\_Categorization\\_and\\_Empirical\\_Evaluation](https://www.researchgate.net/publication/392398351_Knowledge_Tracing_Models_in_Digital_Learning_Historical_Evolution_Categorization_and_Empirical_Evaluation)
4. Enhanced Learning Behaviors and Ability Knowledge Tracing - MDPI, accessed February 8, 2026, <https://www.mdpi.com/2076-3417/15/2/883>
5. Bayesian Knowledge Tracing (BKT) - Emergent Mind, accessed February 8, 2026, <https://www.emergentmind.com/topics/bayesian-knowledge-tracing-bkt>
6. Individualized Bayesian Knowledge Tracing Models, accessed February 8, 2026, <https://www.cs.cmu.edu/~ggordon/yudelson-koedinger-gordon-individualized-bayesian-knowledge-tracing.pdf>
7. Time-dependant Bayesian knowledge tracing—Robots that model user skills over time, accessed February 8, 2026,



- <https://pmc.ncbi.nlm.nih.gov/articles/PMC10925631/>
8. Spectral Bayesian Knowledge Tracing - University of Pittsburgh, accessed February 8, 2026, <https://people.cs.pitt.edu/~falakmasir/docs/EDM2015.pdf>
  9. Parametric Constraints for Bayesian Knowledge Tracing from First Principles - Amazon Science, accessed February 8, 2026, <https://assets.amazon.science/b8/25/bbd83c28452c822e4db44a7f949b/parametric-constraints-for-bayesian-knowledge-tracing-from-first-principles.pdf>
  10. The Misidentified Identifiability Problem of Bayesian Knowledge Tracing - CMU School of Computer Science, accessed February 8, 2026, <https://www.cs.cmu.edu/~shayand/papers/EDM2017.pdf>
  11. Parametric Constraints for Bayesian Knowledge Tracing from First Principles - arXiv, accessed February 8, 2026, <https://arxiv.org/html/2401.09456>
  12. Revisiting Applicable and Comprehensive Knowledge Tracing in Large-Scale Data - AWS, accessed February 8, 2026, [https://ecmlpkdd-storage.s3.eu-central-1.amazonaws.com/preprints/2025/research/preprint\\_ecml\\_pkdd\\_2025\\_research\\_873.pdf](https://ecmlpkdd-storage.s3.eu-central-1.amazonaws.com/preprints/2025/research/preprint_ecml_pkdd_2025_research_873.pdf)
  13. BPSKT: Knowledge Tracing with Bidirectional Encoder Representation Model Pre-Training and Sparse Attention - MDPI, accessed February 8, 2026, <https://www.mdpi.com/2079-9292/14/3/458>
  14. (PDF) Individualized Bayesian Knowledge Tracing Models - ResearchGate, accessed February 8, 2026, [https://www.researchgate.net/publication/249424313\\_Individualized\\_Bayesian\\_Knowledge\\_Tracing\\_Models](https://www.researchgate.net/publication/249424313_Individualized_Bayesian_Knowledge_Tracing_Models)
  15. How Deep is Knowledge Tracing? - Computer Science - University ..., accessed February 8, 2026, <https://home.cs.colorado.edu/~mozer/Research/Selected%20Publications/reprints/KhajahLindseyMozer2016.pdf>
  16. How Deep Is Knowledge Tracing - Scribd, accessed February 8, 2026, <https://www.scribd.com/document/477377328/How-Deep-is-Knowledge-Tracing>
  17. How Deep is Knowledge Tracing? - Educational Data Mining, accessed February 8, 2026, [https://www.educationaldatamining.org/EDM2016/proceedings/paper\\_144.pdf](https://www.educationaldatamining.org/EDM2016/proceedings/paper_144.pdf)
  18. Knowledge Tracing Models' Predictive Performance when a Student ..., accessed February 8, 2026, [https://learninganalytics.upenn.edu/ryanbaker/EDM21\\_paper\\_126.pdf](https://learninganalytics.upenn.edu/ryanbaker/EDM21_paper_126.pdf)
  19. (PDF) A Systematic Review of Knowledge Tracing and Large Language Models in Education: Opportunities, Issues, and Future Research - ResearchGate, accessed February 8, 2026, [https://www.researchgate.net/publication/387053522\\_A\\_Systematic\\_Review\\_of\\_Knowledge\\_Tracing\\_and\\_Large\\_Language\\_Models\\_in\\_Education\\_Opportunities\\_Issues\\_and\\_Future\\_Research](https://www.researchgate.net/publication/387053522_A_Systematic_Review_of_Knowledge_Tracing_and_Large_Language_Models_in_Education_Opportunities_Issues_and_Future_Research)
  20. Exploring Knowledge Tracing in Tutor-Student Dialogues using LLMs, accessed February 8, 2026, [https://learninganalytics.upenn.edu/ryanbaker/Dialogue\\_KT\\_LAK\\_25-2.pdf](https://learninganalytics.upenn.edu/ryanbaker/Dialogue_KT_LAK_25-2.pdf)
  21. A Systematic Review of Knowledge Tracing and Large Language Models in

Education: Opportunities, Issues, and Future Research - arXiv, accessed February 8, 2026, <https://arxiv.org/pdf/2412.09248>

22. [Literature Review] A Systematic Review of Knowledge Tracing and Large Language Models in Education: Opportunities, Issues, and Future Research - Moonlight, accessed February 8, 2026, <https://www.themoonlight.io/en/review/a-systematic-review-of-knowledge-tracing-and-large-language-models-in-education-opportunities-issues-and-future-research>
23. Revisiting Applicable and Comprehensive Knowledge Tracing in Large-Scale Data - arXiv, accessed February 8, 2026, <https://arxiv.org/html/2501.14256v1>
24. arxiv.org, accessed February 8, 2026, <https://arxiv.org/pdf/2501.14256v2>
25. DKT2: Revisiting Applicable and Comprehensive Knowledge Tracing in Large-Scale Data - arXiv, accessed February 8, 2026, <https://arxiv.org/pdf/2501.14256>